RAG SYSTEM MONITOR
PRODUCTION ENVIRONMENT · REAL-TIME ANALYTICS
LIVE 03 MAR 2026
SYSTEM HEALTH OK
01 · RETRIEVAL METRICS
Recall@k
Top-K Sim
Centroid Drift
Tail Queries
0.847
02 · RERANKER METRICS
Score Dist.
Top1 vs Top5 Gap
Compression
Score Compression Zone
Top-1/5 Gap
Δ 0.183
03 · LLM & CONTEXT METRICS
Token Cov
Chunk Rel
Hallu Rate
Citation
Token Cov: 78.4%
Chunk Rel: 82.1%
Hallu: 4.7%
Citation: 91.3%
04 · QUERY & REWRITE METRICS
Rewritten Sim
Raw Sim
Complexity
Domain Coverage
Δ+11%
Rewrite Gain: +11.2%
Query Complexity: 3.8
Domain Coverage: 87.5%
05 · ALARM PANEL
EARLY
Centroid drift ↑ approaching threshold [Δ0.08]
MEDIUM
Top-1/5 gap compressed [Δ0.183 > 0.15]
HIGH
Hallucination rate spiked [4.7% > 4% limit]
CRITICAL
Tail query recall dropped [0.21 << 0.40 min]
ACTIVE ALARMS: 1 EARLY 1 MED 1 HIGH 1 CRIT
SLA: ⊠ AT RISK
RECALL@5 (P95)
0.847
▲ +2.3% vs yesterday
RERANK SCORE P50
0.731
▲ +0.8% compression risk
HALLUCINATION RATE
4.7%
▲ +0.7% — above threshold
REWRITE GAIN
+11.2%
▲ +2.1% improvement
CITATION ACCURACY
91.3%
▲ +3.1% vs last week
ACTIVE ALARMS
1 1 1 1
E/M/H/C
SLA RISK — INVESTIGATE
© 2026 RAG MONITOR v2.4.1
DATA PIPELINE: OPERATIONAL
VECTOR DB: QDRANT 1.9.2
LLM: CLAUDE-SONNET-4
RERANKER: CROSS-ENCODER-MS-MARCO
REFRESH: 30s
ALL SYSTEMS NOMINAL

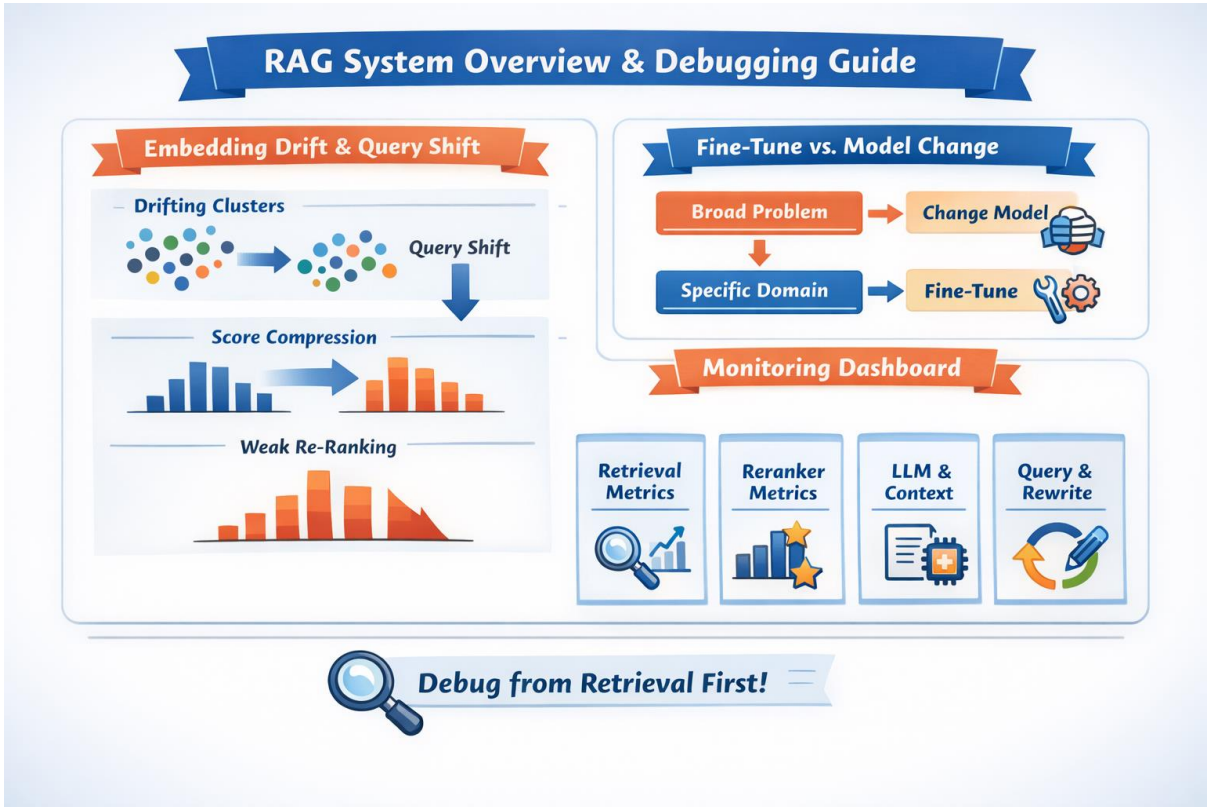
RAG System Overview & Debugging Guide
Embedding Drift & Query Shift
Drifting Clusters
Query Shift
Score Compression
Weak Re-Ranking
Fine-Tune vs. Model Change
Broad Problem
Change Model
Specific Domain
Fine-Tune
Monitoring Dashboard
Retrieval Metrics
Reranker Metrics
LLM & Context
Query & Rewrite
Debug from Retrieval First!

RAG, Embedding ve Production Monitoring

1. Kullanıcı Sorusu ve Motivasyon

- Kullanıcı, yapay zeka mühendisliği perspektifiyle **RAG (Retrieval-Augmented Generation) sistemlerini** ve embedding uzayını anlamak istiyor.
- Özellikle **embedding drift**, **bulut kayması**, **query drift**, **reranker skorları**, ve **production monitoring** konularına odaklandı.
- Amacı, RAG pipeline'ını bilinçli bir şekilde kurmak, her adımı izlemek ve potansiyel sorunları erken tespit etmek.

2. Embedding ve Vektör Uzayı

- **Vektör uzayı**, kelimeler veya cümleler için koordinat sistemi gibi düşünüldü.
- **Embedding modeli**, kelimeleri yüksek boyutlu vektörlere çevirir.
- Bu vektörler uzayda **anlam bulutları (point clouds)** oluşturur: yakın anlamlı query'ler uzayda yakın noktalarda gruplanır.
- **Drift**: Kullanıcı sorguları veya domain değiştikçe, embedding noktaları eski bulutun etrafında toplanmaz → retrieval kalitesi düşer.
- **Query rewriting**, drift'i geçici olarak maskeler: eski buluta benzer forma çevirerek retrieval'ı yapay olarak iyi gösterir.

3. Drift ve Model Körleşmesi

- **Embedding drift** ve **distribution shift** ayrı kavramlar:
  - Embedding drift = yeni verilerin embedding uzayında farklı bölgelerde yoğunlaşması.
  - Model körleşmesi (overfitting) = eğitim verisine fazla bağlılık → yeni veri ile performans düşüşü.

- Kullanıcı, “Yeni query’ler eski buluta neden yaklaşmıyor?” sorusunu sordu ve cevap: model, mevcut production bulutunu **bilmez**; embedding modeli deterministiktir ve kendi anlam haritasına göre konumlandırır.

4. RAG Pipeline Debugging

- RAG pipeline’daki adımlar ve dikkat edilmesi gerekenler:

1. **Veri ve chunking**
    a. Chunk semantik olarak anlamlı olmalı.
    b. Token uzunluğu, overlap ve bilgi yoğunluğu kritik.
2. **Embedding**
    a. Top-k similarity trend, tail query performansı, centroid drift izlenmeli.
3. **First-stage retrieval**
    a. Correct doc top-k içinde mi? Recall@k, MRR.
4. **Reranker**
    a. Score distribution, top-1/top-5 gap, score compression kontrolü.
5. **Context & LLM**
    a. Context token coverage, chunk relevance, hallucination/citation rate.
6. **Query & Rewrite**
    a. Raw vs rewritten similarity, query complexity trend, domain coverage.

- Senior mühendis bakış açısı: Çöküşler **yukarıdan değil aşağıdan başlar**.

5. Önemli Sinyaller / Ölümcül Alarm

1. **Top-k similarity düşüşü** → embedding veya retrieval drift
2. **Reranker score compression** → ayrışma kaybı, top-1 seçim risk altında
3. **Tail query performansı düşüşü** → embedding domain yetersizliği
4. **LLM hallucination artışı** → context veya prompt problemi

- Early warning, genellikle **retrieval trendleri** ile gelir.

6. Eğitim vs Fine-Tune Kararı

- Geniş problem → embedding modelini değiştir
- Dar domain problemi → fine-tune et

- Önce güçlü pretrained model denenmeli, fine-tune son çare.

7. Quiz ile Öğrenilenler

- Retrieval her zaman ilk bakılacak yer
- Score compression = reranker ayrışma kaybı
- Embedding drift = veri dağılımı değişikliği
- Tail query performansı = embedding domain problemi
- Query rewriting = drift'i maskeler
- Top-k similarity trend = erken alarm sinyali

(Kullanıcı quizde 10/10 yaptı, tüm kavramları pekiştirdi.)

8. Dashboard / Production Monitoring

- Panel önerileri:

1. **Retrieval Metrics:** Recall@k, similarity trend, centroid drift, tail vs head
2. **Reranker Metrics:** Score distribution, top-1/top-5 gap
3. **LLM & Context Metrics:** Token coverage, chunk relevance, hallucination/citation
4. **Query & Rewrite Metrics:** Raw vs rewritten similarity, query complexity, domain coverage
5. **Alarms Panel:** Early/medium/high/critical alarm renkleri

- Bu dashboard, sistemi **real-time izleme** ve **proaktif müdahale** için tasarlandı.

9. Son Nokta

- Kullanıcı, artık **embedding, drift, retrieval, reranker ve LLM ilişkilerini** ve **production pipeline izlemesini** net şekilde kavradı.
- Bir sonraki adım: dashboard mockup'u çizdirme promptu hazırlandı ve görselleştirme için kullanılabilir.