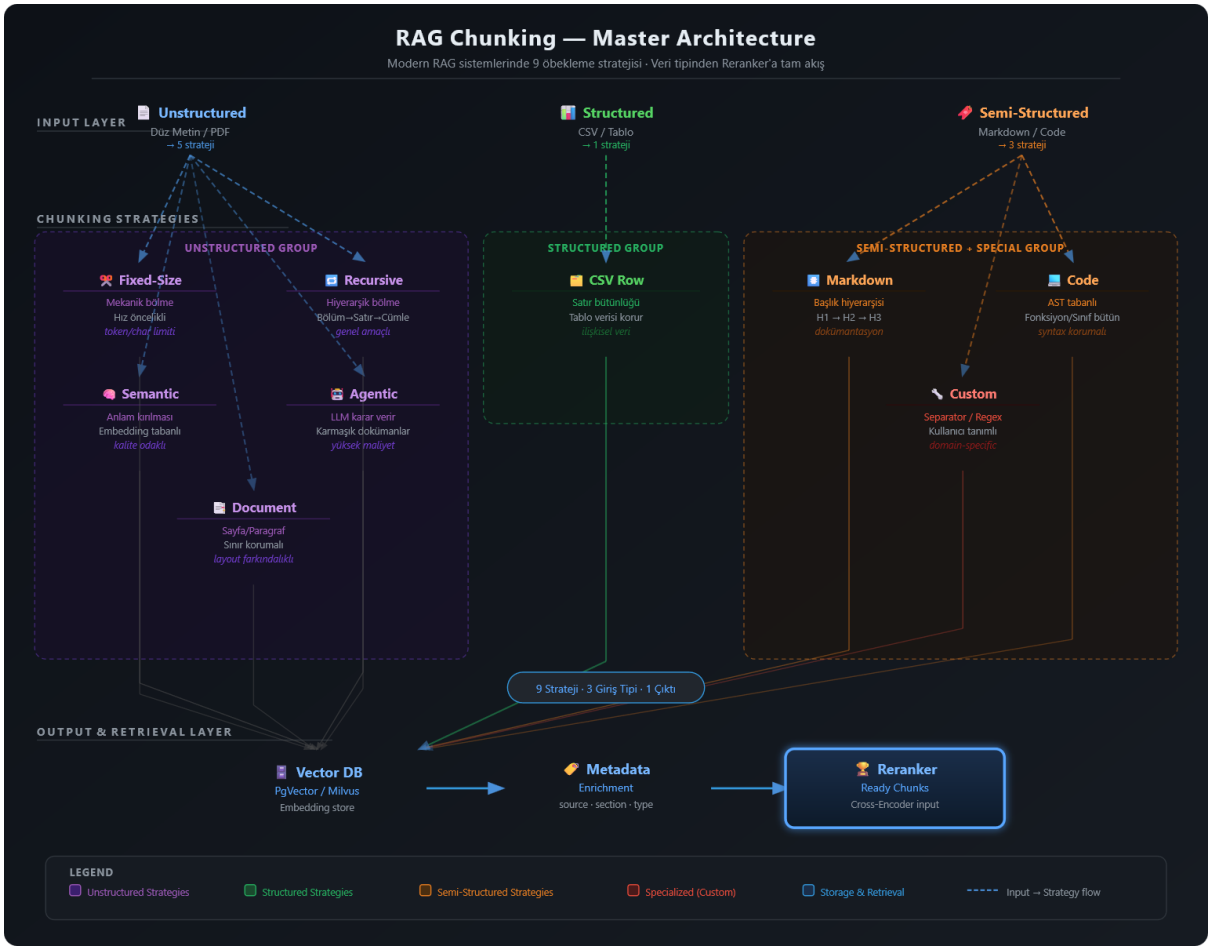

RAG Mimarilerinde Anlamsal Öbekleme ve Hiyerarşik Arama Stratejileri

Giriş

Bu rapor, büyük dil modelleri (LLM) ile entegre çalışan yüksek performanslı bir Geri Getirme Destekli Üretim (RAG) sisteminin uçtan uca mimarisini tanımlar. Başarılı bir RAG sistemi sadece veriyi saklamak değil; onu anlamsal bütünlüğü koruyarak parçalamak, doğru matematiksel uzayda hizalamak ve en alakalı bilgiyi milisaniyeler içinde yeniden sıralamak üzerine kuruludur.

1. Veri İşleme ve Gelişmiş Öbekleme (Chunking) Stratejileri

Verinin parçalanma biçimi, sistemin "hatırlama" kalitesini doğrudan belirler. Geleneksel sabit boyutlu bölme yöntemleri yerine, doküman yapısına duyarlı stratejiler önceliklendirilmelidir.

Bağlam Duyarlı Yöntemler

- **Cümle Penceresiyle Alma (Sentence Window):** Veri cümle düzeyinde indekslenir, ancak LLM'e sunulurken çevresindeki ±3 cümleyle genişletilir. Bu sayede zamirlerin (o, bu, onlar) kime ait olduğu gibi bağlamsal detaylar korunur.

- **Anlamsal Öbekleme (Semantic Chunking):** Karakter sayısına değil, konunun değiştiği "anlamsal kırılma" noktalarına odaklanır. Cümleler arası benzerlik bir eşiğin altına düştüğünde yeni bir parça başlatılır.

Hiyerarşik ve Dinamik Yapılar (Parent-Child)

Karmaşık dökümanlar için metni bir aile ağacı gibi (2048 -> 512 -> 128 token) organize etmek gerekir.

- **HiChunk (Tencent 2025):** Geleneksel sabit hiyerarşilerin ötesinde, model tabanlı çıkarım ile döküman yapısını anlar. "Auto-Merging" özelliği sayesinde, arama anında bulunan küçük kanıt parçaları (child), eğer yoğun bilgi içeriyorsa otomatik olarak üst bağlamla (parent) birleştirilir. Bilgi kaybını %30-40 oranında azaltır.

Agno (Phidata) Ekosistemi Öbekleme Modelleri

Agno mimarisinde döküman tipine göre özelleşmiş şu stratejiler kullanılır:

- **Recursive:** Paragraf, satır ve cümle hiyerarşisini izler; CV'lerde madde işaretlerinin bölünmesini engeller.
- **Document & Markdown:** Dokümanın iskeletine (# H1, ## H2) sadık kalarak hiyerarşiyi korur.
- **Code Chunking:** Soyut Sözdizimi Ağaçları (AST) kullanarak fonksiyon ve sınıf bütünlüğünü korur.
- **Agentic Chunking:** Öbekleme sınırlarına bir yapay zeka modelinin "muhakemesi" ile karar verilir.

2. Seçim Matrisi: Hangi Veriye Hangi Yöntem?

Öbekleme Yöntemi	En İyi Kullanım Durumu	Temel Avantajı	HR Sistemindeki Kritik Rolü
Fixed-Size	Hızlı prototipleme, çok büyük veri setleri.	Düşük CPU maliyeti ve yüksek hız.	Standart dökümanları hızla indekslemek için temel katman.
Recursive	**Özgeçmişler (CV)** ve dökümanlar.	Paragraf ve liste bütünlüğünü korur.	İş deneyimi maddelerinin (bullet points) bölünmesini engeller.

Semantic	Konu geçişli uzun makaleler, el kitapları.	Anlam kırılmalarını tespit eder.	"Eğitim" ve "Deneyim" bölümlerini anlamsal olarak ayırır.
Document	Sayfa düzeni net olan PDF ve raporlar.	Döküman iskeletine sadık kalır.	Sayfa sınırlarına göre mantıklı parçalama yapar.
CSV Row	Aday listeleri, maaş tabloları, loglar.	Veri satırı (record) bütünlüğünü korur.	Tablo halindeki aday verilerini tek bir parça olarak tutar.
Markdown	README dosyaları, teknik notlar.	Başlık hiyerarşisini (#, ##) anlar.	Teknik dökümanlardaki hiyerarşik yapıyı korur.
Agentic	Çok karmaşık ve dağınık metinler.	Model (LLM) kararıyla akıllı bölme.	Dağınık CV formatlarında "en mantıklı" bölme noktasını bulur.
Code	Yazılım projeleri, Python dosyaları.	AST ile fonksiyon/sınıf bütünlüğünü korur.	Adayın paylaştığı kod örneklerini fonksiyon bazlı indeksler.
Custom	Özel ayırıcılı (---, ***) raporlar.	Terzi usulü, kurallı bölme.	Şirkete özel formlardaki verileri regex ile hatasız böler.

3. Embedding Seçimi ve Görev Odaklı Hizalama

Vektörel uzayda sorgu ile dökümanı hizalamak için modern modeller "önek" (prefix) mekanizmasını kullanır.

- **SOTA Modeller:**
  - **BGE-M3:** 8k Token desteği ve Hibrit (Dense+Sparse+Multi-Vector) arama yeteneği.
  - **Nomic v1.5:** Matryoshka özelliği ile boyut esnekliği (768'den 128'e düşürülebilir).
- **Asimetrik Arama Çözümü:** Sorgular kısa, belgeler uzundur. `search_query:` ve `search_document:` gibi önekler kullanılarak, modelin soruyu ve cevabı aynı anlamsal uzayda eşleştirmesi sağlanır.

4. Gelişmiş Arama ve Hibrit Mimari

En sağlam mimari, farklı arama tiplerini aynı koleksiyonda birleştiren **Hibrit Arama**'dır.

- **ColBERT (Late Interaction):** Vektörleri tek bir noktaya sıkıştırmak yerine her terimi ayrı ayrı işler. "MaxSim" operatörü ile sorgudaki her kelime, dokümandaki en benzer karşılığıyla eşleşir.
- **Koleksiyon Yapılandırması:**
    - **Dense:** Genel anlamsal benzerlik (Cosine).
    - **Sparse (BM25):** Anahtar kelime odaklı hassasiyet.
    - **ColBERT:** Derin bağlamsal doğrulama.

5. İki Aşamalı Sıralama (Reranking) ve Orkestrasyon

Arama süreci hız ve doğruluk dengesi için ikiye bölünmelidir:

1. **Retrieval:** Hızlı bir şekilde ilk 100 aday döküman getirilir.
2. **Reranking:** BGE-Reranker veya ColBERT gibi ağır ama çok hassas modellerle en iyi 5 döküman seçilir.

Agno Entegrasyonu: Agno Agent'ı, bu süreci bir "Tool" olarak yönetir. Sorgunun tipine göre hangi öbekleme seviyesine (detaylı mı yoksa özet mi) bakacağına ajan kendisi karar verir.

Bu mimari; verinin parçalanmasından (Recursive/HiChunk), saklanmasına (BGE-M3) ve dinamik olarak yeniden sıralanmasına kadar uçtan uca yüksek sadakatli bir yapı sunar. 2025 standartlarında bir RAG sistemi, sadece bilgi getiren değil, bilginin hiyerarşisini ve bağlamını anlayan bir sistemdir.